Análise Estatística Descritiva do Dataset de Eleições Brasileiras de 2014: Gastos de Campanha, Votos e Desigualdades Regionais entre Candidatos a Deputado Federal

Heitor Teixeira - 2651254
MBA: Ciência de Dados
UNIFOR
Fortaleza, Brasil
heitor.mba.unifor@gmail.com

***Resumo*—Este artigo apresenta uma análise estatística descritiva do dataset de eleições brasileiras de 2014 (D2), com foco na relação entre recursos financeiros de campanha e desempenho eleitoral de candidatos a Deputado Federal. O arquivo original contém 6.353 candidaturas, das quais 5.323 registraram gasto positivo e foram mantidas nas análises centrais sobre financiamento. Além das exigências do briefing da disciplina, o trabalho enriquece o dataset com bases públicas do TSE, adicionando informações de partido, gênero, raça, situação eleitoral e fornecedores. O relatório cobre os histogramas de votos e gasto para três UFs escolhidas pelo autor (RJ, GO e AM), os respectivos gráficos de dispersão com correlação de Pearson, a correlação por UF para todo o país e uma tabela-resumo de medidas de tendência central e dispersão por estado. Como resultados principais, a distribuição de gastos mostrou assimetria extrema à direita em todos os recortes, com mediana nacional de R$ 9.916 frente à média de R$ 220.397. A correlação entre gasto e votos foi positiva em todo o país, com $r = 0{,}593$ no agregado nacional, $r = 0{,}556$ no RJ, $r = 0{,}605$ em GO e $r = 0{,}902$ no AM. As análises extras mostram ainda forte concentração de recursos em homens e candidatos brancos, além da relevância de comitês partidários e fornecedores gráficos no financiamento eleitoral de 2014.**

***Index Terms*—Estatística descritiva, eleições 2014, financiamento de campanha, correlação de Pearson, visualização de dados.**

I. Introdução

Este trabalho realiza a análise do dataset D2 proposto na disciplina de Estatística Descritiva, composto por informações de votos e recursos financeiros de campanha de candidatos a Deputado Federal nas eleições brasileiras de 2014.

O briefing do professor exige, para esse dataset, quatro blocos de análise: (i) histogramas de votos e dinheiro para três UFs escolhidas pelo aluno; (ii) gráficos de dispersão entre dinheiro e votos, com correlação de Pearson, para essas mesmas UFs; (iii) uma tabela com a correlação dinheiro $\times$ votos para todas as UFs presentes no dataset; e (iv) uma tabela-resumo por estado com média, mediana, desvio padrão, mínimo, máximo, Q_1 e Q_3 para as variáveis votos e dinheiro.

Além de cumprir integralmente esses requisitos, o notebook original foi além do escopo mínimo da atividade: houve enriquecimento com bases públicas do TSE, validação dos dados mesclados, análises nacionais agregadas, estudo de fornecedores e investigação de desigualdades por gênero e raça. Este artigo mantém esse espírito, mas seleciona apenas as figuras mais informativas para evitar excesso de redundância.

II. Fundamentação Teórica

A. Estatística Descritiva

A estatística descritiva reúne técnicas para organizar, resumir e interpretar um conjunto de dados sem avançar para inferência causal. Em problemas eleitorais, ela permite comparar perfis de gasto, dispersão de votos e heterogeneidade entre estados, partidos e grupos sociais.

B. Medidas de Posição, Dispersão e Separatrizes

Média e mediana resumem a posição central dos dados, mas se comportam de forma distinta diante de distribuições assimétricas. Quando poucos candidatos concentram gastos muito altos, a média tende a superestimar o comportamento do candidato típico, enquanto a mediana permanece mais robusta. Medidas como desvio padrão, mínimo, máximo, Q_1 e Q_3 complementam essa leitura ao descrever dispersão e amplitude.

C. Histogramas, Escala Logarítmica e Cauda Longa

Histogramas permitem visualizar a frequência de valores ao longo do eixo numérico. Em bases eleitorais, tanto votos quanto gastos costumam apresentar forte assimetria à direita, com grande concentração em faixas baixas e poucos casos extremos muito acima da massa de candidatos. Nesses contextos, o uso de escala logarítmica melhora substancialmente a legibilidade dos gráficos.

D. Gráficos de Dispersão e Correlação de Pearson

O gráfico de dispersão permite observar visualmente como duas variáveis se relacionam. Para quantificar essa associação linear, utiliza-se o coeficiente de correlação de Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{1}$$

Valores positivos indicam associação direta; valores próximos de zero sugerem relação linear fraca; e valores mais próximos de 1 indicam relação mais forte. No entanto, correlação não implica causalidade.

III. Metodologia

A. Dataset Original e Filtragem

O arquivo base utilizado foi `eleicoes.csv`, fornecido pelo professor, com as colunas Estado, Número do Candidato, Dinheiro de Campanha e Votos. Cada linha representa uma candidatura a Deputado Federal em 2014.

As análises centrais de gasto foram conduzidas apenas com candidatos com `Gasto > 0`. Essa decisão metodológica foi adotada por três motivos: (i) o objetivo do estudo é compreender comportamento de financiamento; (ii) cerca de 15% dos registros não apresentavam gasto declarado; e (iii) nenhum candidato eleito no dataset registrou gasto zero, o que reduz o risco de excluir casos substantivamente relevantes para as comparações de desempenho eleitoral.

B. Enriquecimento com Bases do TSE

Embora o briefing não exigisse feature engineering, o dataset foi enriquecido com duas bases públicas do TSE: a prestação de contas de despesas e o cadastro oficial de candidatos. A partir desses arquivos, foram agregadas variáveis como nome, partido, CPF, quantidade de notas fiscais, total de despesas no TSE, gênero, raça, escolaridade, estado civil e situação eleitoral.

Os merges foram realizados por chave composta `Estado + Numero Candidato`, evitando colisões entre candidatos de UFs distintas com mesmo número. O arquivo enriquecido foi salvo localmente para reprodutibilidade e reaproveitamento nas execuções seguintes.

C. Validação dos Dados Mesclados

Após o enriquecimento, foi feita uma etapa de validação com dois objetivos: (i) verificar completude do cruzamento entre o dataset original e as bases do TSE; e (ii) comparar `Gasto` com `Total_Despesas_TSE`.

Essa etapa foi operacionalizada por meio de uma tabela de completude, de uma comparação gráfica entre os valores do dataset original e os valores agregados do TSE, e de uma contagem das divergências mais relevantes por UF. Os achados dessa validação são apresentados na Seção IV-A.

D. Escolha dos Estados

As três UFs selecionadas para cumprir o briefing foram Rio de Janeiro (RJ), Goiás (GO) e Amazonas (AM). A seleção buscou garantir diversidade regional e de escala analítica, combinando um estado grande do Sudeste, um estado de porte intermediário do Centro-Oeste e um estado do Norte com menor número de candidaturas.

E. Procedimentos Analíticos

A análise foi estruturada em quatro blocos. Primeiro, foram produzidas estatísticas descritivas e visualizações agregadas do Brasil para contextualizar a distribuição nacional dos recursos. Em seguida, foram construídos histogramas de gasto e votos para as três UFs selecionadas, com uso de escala logarítmica quando necessário. Na terceira etapa, foram gerados gráficos de dispersão entre gasto e votos, acompanhados do coeficiente de correlação de Pearson para cada recorte estadual e para o conjunto das UFs. Por fim, com base no dataset enriquecido, foram incluídas análises complementares de validação, fornecedores e desigualdades por gênero e raça.

IV. Resultados e Discussão

A. Validação dos Dados Mesclados

Os resultados da validação mostraram boa aderência entre o dataset original e as bases do TSE. Na checagem de completude, apenas quatro candidatos com gasto positivo não foram encontrados na base enriquecida, indicando cobertura muito alta do cruzamento. Já na comparação entre `Gasto` e `Total_Despesas_TSE`, a maior parte dos pontos permaneceu próxima da diagonal, sugerindo consistência entre as duas fontes.

As divergências residuais parecem concentrar-se em poucos casos e podem ser explicadas, em boa parte, por arredondamento ou por diferentes versões da prestação de contas utilizadas ao longo do processo de consolidação dos dados. Como o briefing da atividade se baseia no arquivo fornecido pelo professor, a variável `Gasto` foi mantida como referência principal em todas as análises do artigo.

[PLACEHOLDER]

Inserir screenshot da Tabela 2.3.1 do notebook.

Figura 1: Completude do cruzamento entre `eleicoes.csv` e as bases do TSE.

B. Caracterização Inicial do Dataset Enriquecido

O processo de preparação resultou em um dataset analítico com 6.353 candidaturas distribuídas em 26 UFs presentes no arquivo original e 32 partidos distintos. As variáveis de gênero, raça e situação eleitoral foram recuperadas para 6.349 registros, o que garante cobertura quase completa para as análises complementares de representatividade. Além disso, a base auxiliar de fornecedores reuniu 366.289 registros de despesas, permitindo observar não apenas quanto cada candidato gastou, mas também para onde os recursos foram transferidos.

Essa ampliação é importante porque transforma o problema original, centrado apenas em votos e dinheiro, em uma base mais rica para examinar desigualdade, intermediação partidária e estrutura econômica das campanhas. Assim, o artigo mantém o núcleo exigido pelo briefing, mas passa a interpretar o fenômeno com maior profundidade substantiva.

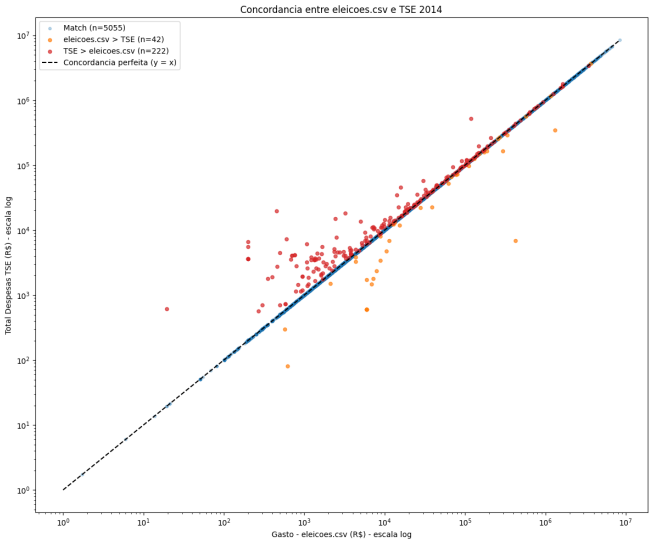

(a) Comparação entre gasto do dataset original e total apurado no TSE.

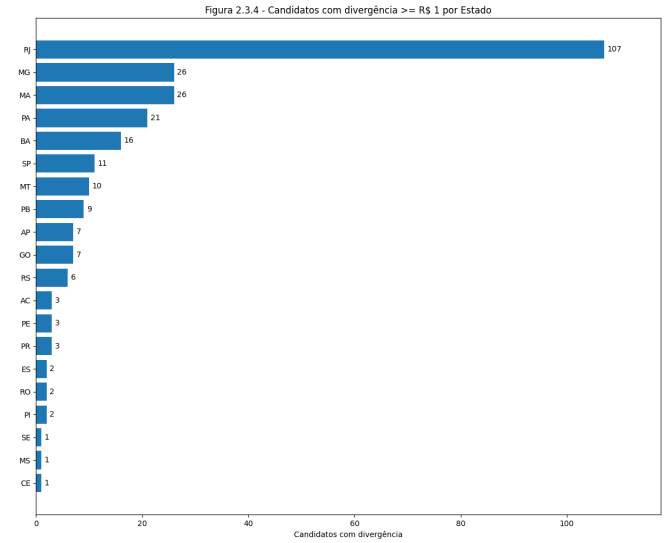

(b) Distribuição das divergências relevantes por UF.

Figura 2: Validação dos dados enriquecidos. Os gráficos mostram alta concentração de pontos próximos à diagonal e divergências localizadas, sem comprometer a análise descritiva principal.

C. Panorama Nacional do Dataset

Após a filtragem por gasto positivo, restaram 5.323 candidaturas para análise de financiamento. A média nacional de gasto foi de R$ 220.397, enquanto a mediana foi de apenas R$ 9.916, diferença que evidencia forte assimetria à direita. O gasto máximo observado ultrapassou R$ 8,4 milhões. Em votos, a mediana nacional entre candidatos com gasto e votos positivos foi de 1.772, frente a média de 18.045.

[PLACEHOLDER]

Inserir screenshot da Tabela 3.1 do notebook.

Figura 3: Estatísticas descritivas do dataset nacional de eleições 2014.

No agregado nacional, SP, MG e RJ concentram os maiores volumes absolutos de gasto. Contudo, quando se observa gasto médio por candidatura, estados menores passam a ocupar posições superiores. Esse contraste reforça que total e média capturam fenômenos distintos: tamanho do mercado eleitoral e intensidade de investimento por candidato.

D. Estrutura Partidária do Financiamento

A distribuição dos recursos entre partidos ajuda a entender como o gasto de campanha se organiza politicamente no plano nacional. Quando se observa o valor total investido, partidos grandes e competitivos concentram mais recursos absolutos. Já o gasto médio por candidatura destaca estratégias de concentração, nas quais poucos nomes recebem valores muito superiores à média nacional.

No ranking de gasto total, PT, PMDB, PSDB e PP aparecem entre os principais partidos de 2014, refletindo capilaridade nacional e maior capacidade de financiamento. Já o gasto médio por candidatura revela outra lógica: partidos com menos candidaturas podem aparecer no topo por concentrarem seus recursos em poucos nomes competitivos. Essa diferença reforça que a média, em contextos eleitorais, pode ser lida como indicador de intensidade estratégica mais do que de presença nacional.

E. Gasto versus Votos no Brasil

O gráfico de dispersão nacional mostra que candidatos eleitos se concentram, em geral, no quadrante superior direito, combinando mais gasto e mais votos. Também se observa uma faixa de gasto abaixo da qual a eleição se torna rara, o que sugere a existência de um patamar mínimo de visibilidade eleitoral.

O coeficiente de Pearson nacional foi $r = 0{,}593$, caracterizando correlação moderada positiva. Em termos substantivos, isso significa que mais dinheiro tende a estar associado a mais votos, mas o gasto, isoladamente, não explica todo o desempenho eleitoral.

F. Requisitos Obrigatórios do Briefing: Três Estados

As subseções seguintes cobrem integralmente o item obrigatório do professor para três UFs escolhidas: histogramas de gasto e votos, além do gráfico de dispersão com correlação de Pearson.

1) Rio de Janeiro (RJ): No RJ, 810 candidaturas registraram gasto positivo. A distribuição de gasto é fortemente assimétrica à direita, com mediana de R$ 6.024 frente a média de R$ 136.771. A distribuição de votos também apresenta

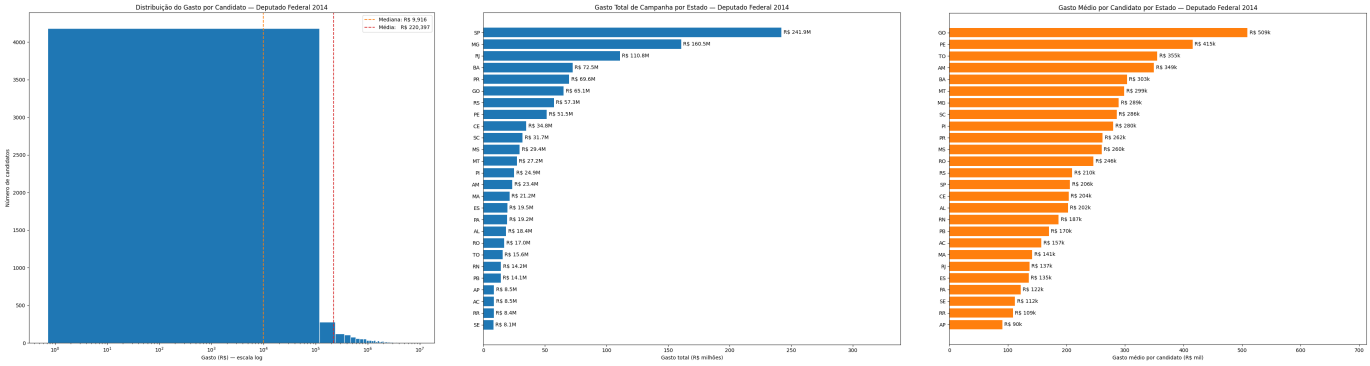

(a) Distribuição nacional do gasto. (b) Top estados por gasto total. (c) Top estados por gasto médio.

Figura 4: Panorama nacional dos recursos de campanha. O histograma mostra forte concentração em baixos valores e cauda longa à direita. Já a comparação entre gasto total e gasto médio revela que estados mais populosos concentram volume absoluto, enquanto estados menores podem liderar em investimento médio por candidatura.

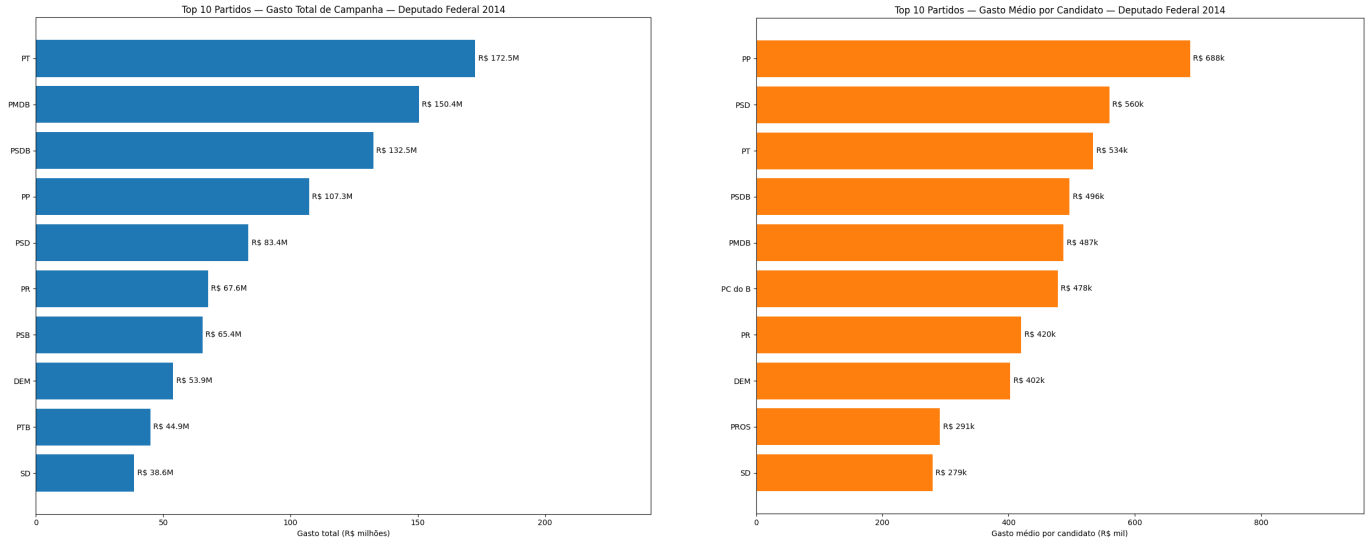

(a) Top partidos por gasto total. (b) Top partidos por gasto médio por candidatura.

Figura 5: Estrutura partidária do financiamento eleitoral no Brasil. O contraste entre gasto total e gasto médio revela que volume agregado e concentração por candidatura são dimensões distintas do financiamento.

cauda longa, com muitos casos em baixas contagens e poucos candidatos concentrando centenas de milhares de votos.

O coeficiente de Pearson no RJ foi $r = 0{,}556$, indicando correlação moderada positiva. Visualmente, a nuvem de pontos confirma a tendência geral de aumento dos votos com o gasto, mas com dispersão considerável e presença de candidatos que gastaram muito sem retorno proporcional nas urnas.

2) Goiás (GO): Em GO, 128 candidaturas tiveram gasto positivo. O estado apresenta um dos quadros mais extremos de concentração: mediana de gasto de R$ 4.048 e média de R$ 508.946. Esse afastamento mostra que poucos candidatos, muito acima da massa de competidores, puxam fortemente a média para cima.

O coeficiente de Pearson em GO foi $r = 0{,}605$, também caracterizando correlação positiva de intensidade moderada. A associação é ligeiramente mais forte que no RJ, sugerindo que, em Goiás, o gasto se alinha um pouco mais ao desempenho eleitoral observado.

3) Amazonas (AM): O AM possui apenas 67 candidaturas com gasto positivo entre os registros analisados, o que gera histogramas com menor resolução. Ainda assim, a forma das distribuições permanece assimétrica à direita, tanto para gasto quanto para votos.

No AM, o coeficiente de Pearson foi $r = 0{,}902$, a relação mais forte entre os três estados escolhidos. O gráfico de dispersão mostra uma tendência linear muito mais nítida do que em RJ e GO, embora o menor número de candidatos torne o resultado mais sensível a casos extremos.

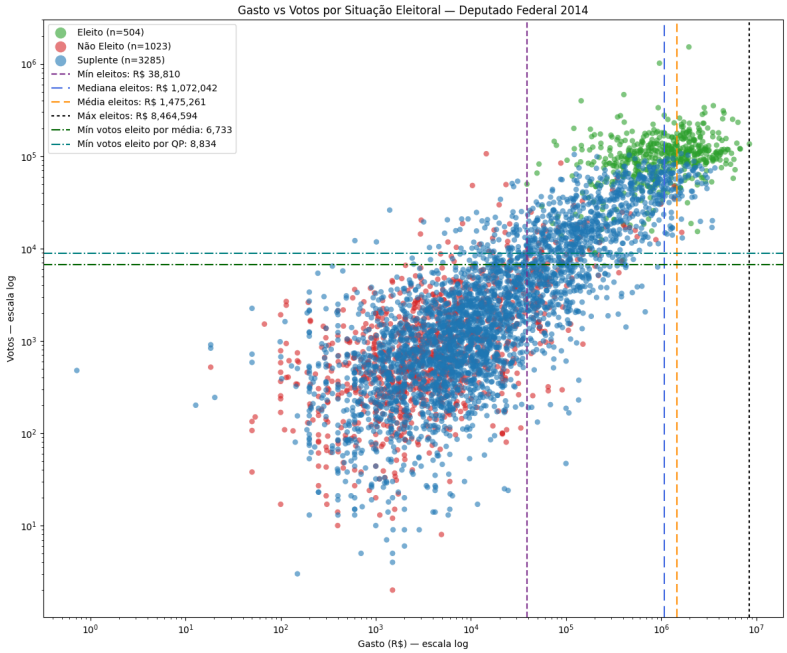

(a) Dispersão nacional entre gasto e votos.

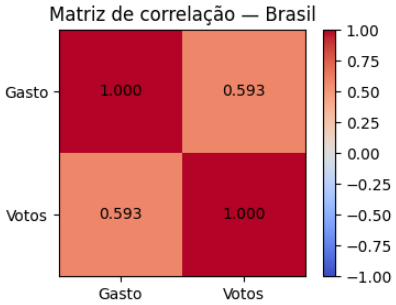

(b) Matriz de correlação nacional.

Figura 6: Relação entre recursos de campanha e desempenho eleitoral no agregado nacional. A associação é positiva, porém não determinística: candidatos com maior gasto tendem a receber mais votos, mas a dispersão permanece elevada.

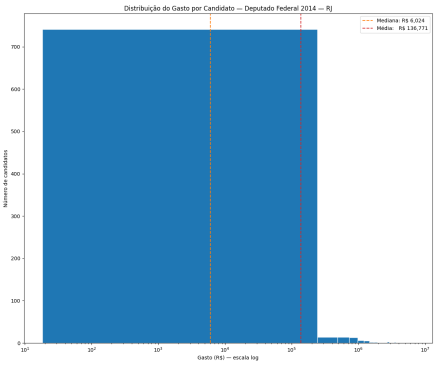

(a) Histograma do gasto.

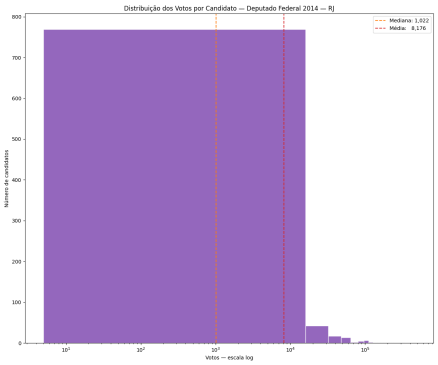

(b) Histograma dos votos.

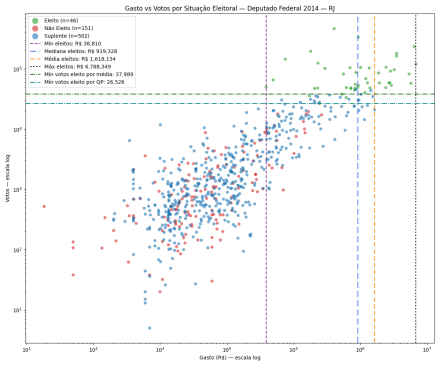

(c) Dispersão gasto × votos.

Figura 7: Análise descritiva do Rio de Janeiro. Os histogramas confirmam concentração em baixos valores com cauda longa, e o gráfico de dispersão mostra separação razoável entre eleitos e não eleitos.

G. Correlação por UF e Tabela-Resumo por Estado

O briefing também exige a correlação de Pearson entre gasto e votos para todas as UFs presentes no dataset, além de uma tabela-resumo com medidas de posição e dispersão por estado. Esses dois resultados são apresentados nas Tabelas 10 e 11, que devem ser inseridas a partir dos screenshots gerados no notebook.

[PLACEHOLDER]

Inserir screenshot da Tabela 3.8 do notebook.

Figura 10: Coeficiente de correlação de Pearson entre gasto e votos por UF.

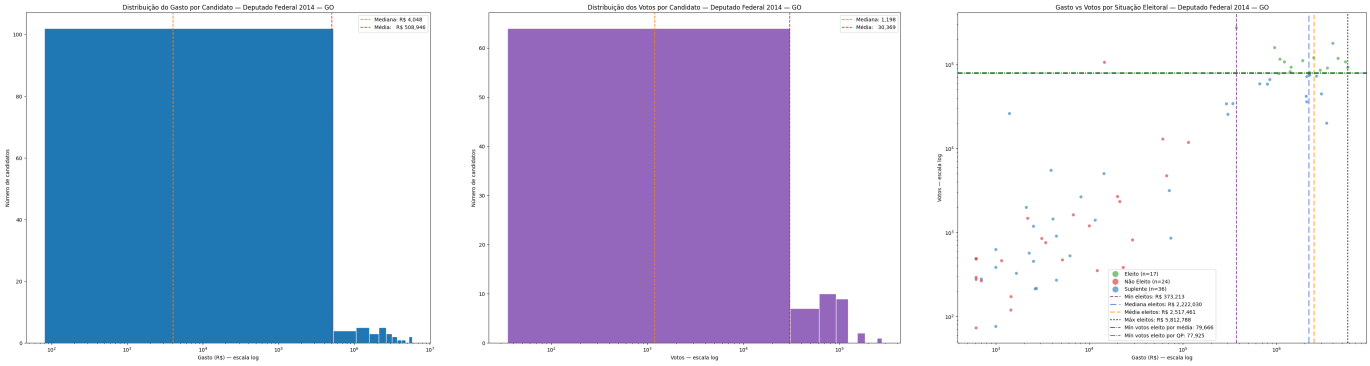

(a) Histograma do gasto. (b) Histograma dos votos. (c) Dispersão gasto $\times$ votos.

Figura 8: Análise descritiva de Goiás. O estado combina forte assimetria em gasto e votos com clara separação entre candidatos eleitos e não eleitos no plano gasto $\times$ votos.

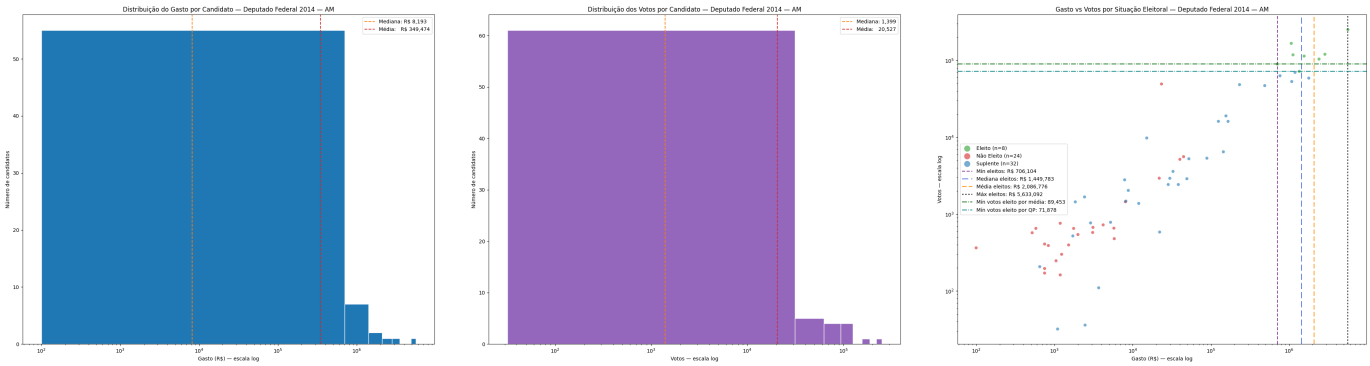

(a) Histograma do gasto. (b) Histograma dos votos. (c) Dispersão gasto $\times$ votos.

Figura 9: Análise descritiva do Amazonas. Mesmo com menor número de observações, os gráficos mostram forte concentração em baixos valores e uma relação visualmente mais clara entre recursos e votos.

[PLACEHOLDER]

Inserir screenshot da Tabela 3.9 do notebook.

Figura 11: Tabela-resumo por UF com medidas de tendência central e dispersão para votos e gasto.

No conjunto das UFs, a correlação foi positiva em todas as unidades presentes na base. Os valores mais altos se concentram em estados com menos candidatos, como AM, enquanto estados muito heterogêneos, como SP e RJ, tendem a exibir correlações mais moderadas. Esse padrão é coerente com a ideia de que mercados eleitorais maiores comportam mais estratégias, perfis e trajetórias de campanha.

H. Análises Extras do Notebook

1) Fornecedores e Setores Econômicos: O enriquecimento com a base de fornecedores permite observar para onde o dinheiro de campanha foi direcionado. No agregado nacional, a categoria `#NULO` lidera o ranking setorial, mostrando que parcela expressiva das despesas não possui classificação econômica detalhada. Entre os setores classificados, destacam-se organizações políticas, serviços gráficos e comunicação visual, coerentes com a infraestrutura típica de campanhas eleitorais em 2014.

O ranking de fornecedores reforça essa leitura: gráficas e empresas de comunicação visual dominam as maiores posições, enquanto comitês eleitorais aparecem como importantes intermediários de repasse. Isso sugere que a campanha de 2014 operava por uma combinação de estrutura partidária, serviços de material publicitário e coordenação financeira centralizada.

Os dois gráficos, em conjunto, mostram também que o financiamento não se concentrava em um único agente dominante. Mesmo os maiores fornecedores representam apenas frações do volume total movimentado, o que indica uma rede ampla de pagamentos distribuídos entre empresas, comitês e prestadores de serviço. Em termos descritivos, trata-se de uma estrutura simultaneamente centralizada no plano partidário e pulverizada no plano operacional.

2) Desigualdades por Gênero e Raça: As figuras a seguir sintetizam um dos achados mais relevantes do notebook: o acesso aos recursos financeiros é bastante desigual entre grupos sociais, e essa desigualdade reaparece no próprio resultado

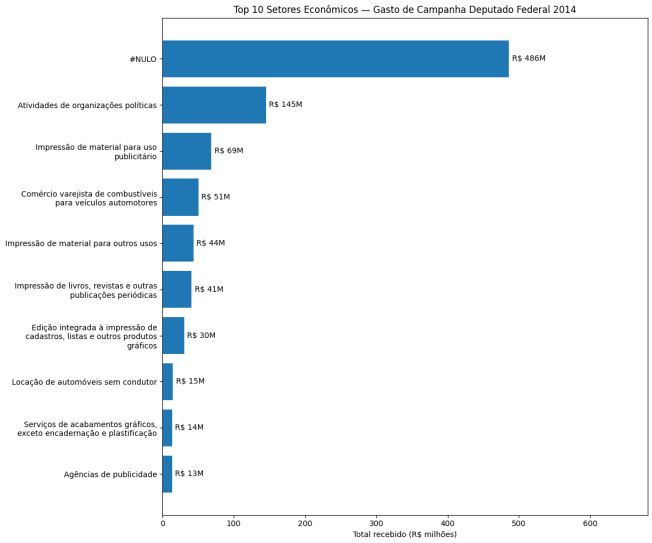

(a) Top 10 setores econômicos por valor recebido.

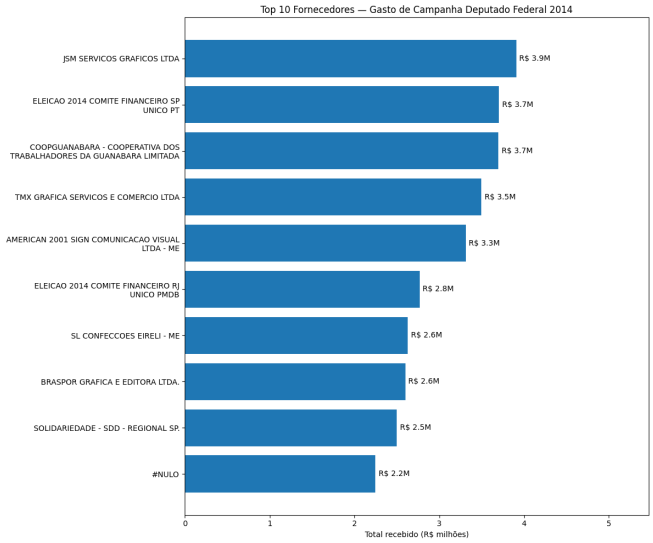

(b) Top fornecedores por valor recebido.

Figura 12: Estrutura econômica das campanhas no agregado nacional. Os gráficos mostram a relevância de setores gráficos e de organizações partidárias, além da forte pulverização dos pagamentos entre fornecedores.

eleitoral.

No Brasil, homens representam 70,4% das candidaturas, mas concentram 90,4% do gasto total. Mulheres, por sua vez, são 29,6% dos candidatos e acessam apenas 9,6% dos recursos; sua taxa de eleição também é muito inferior à masculina (2,9% contra 10,6%). Entre os grupos raciais, candidatos brancos são 58,7% das candidaturas, porém concentram 82,0% do gasto, enquanto pardos e pretos ficam muito abaixo de sua participação relativa em número de candidaturas.

A desigualdade aparece também no nível individual de financiamento. No notebook, a mediana de gasto masculino (R$ 9.299) foi 4,6 vezes a mediana feminina (R$ 2.003). Entre os grupos raciais, candidatos brancos também apresentaram as maiores medianas de gasto entre os grupos com presença relevante na base, sugerindo que a barreira não está apenas no volume total, mas também na distribuição interna dos recursos por candidatura.

Os gráficos de taxa de eleição ajudam a fechar essa interpretação. Eles mostram que a sub-representação não termina no financiamento: grupos que recebem menos recursos em termos proporcionais também tendem a converter uma fração menor de suas candidaturas em cadeiras. Assim, a desigualdade observada no gasto parece atuar não apenas como diferença contábil, mas como parte da estrutura competitiva que organiza as chances de sucesso eleitoral.

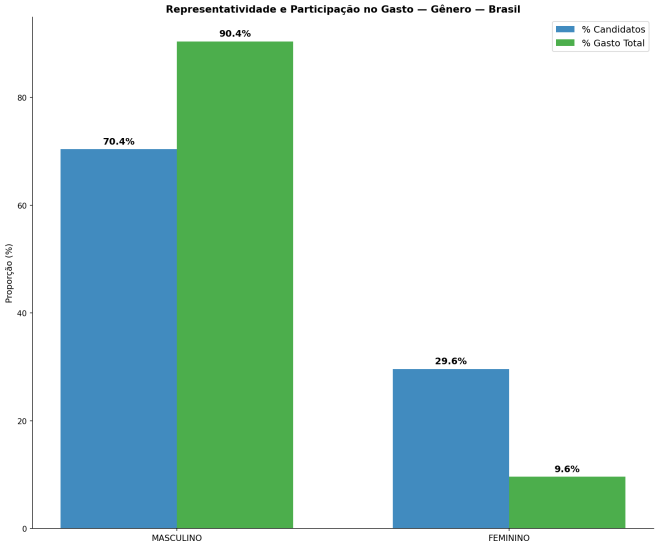

(a) Representatividade e gasto por gênero.

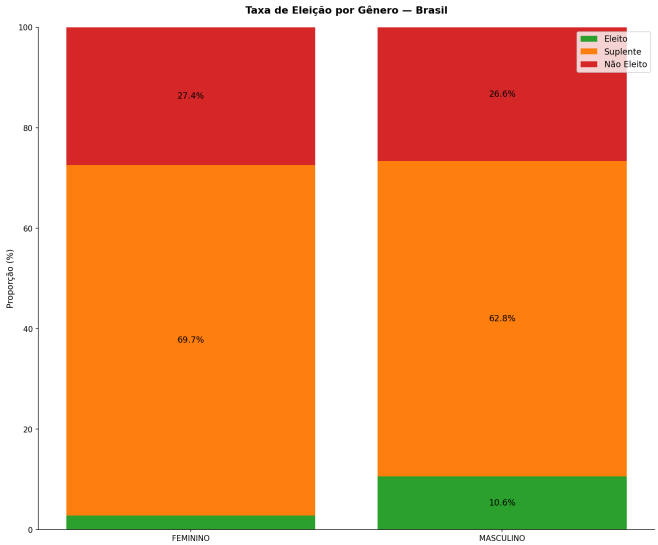

(b) Taxa de eleição por gênero.

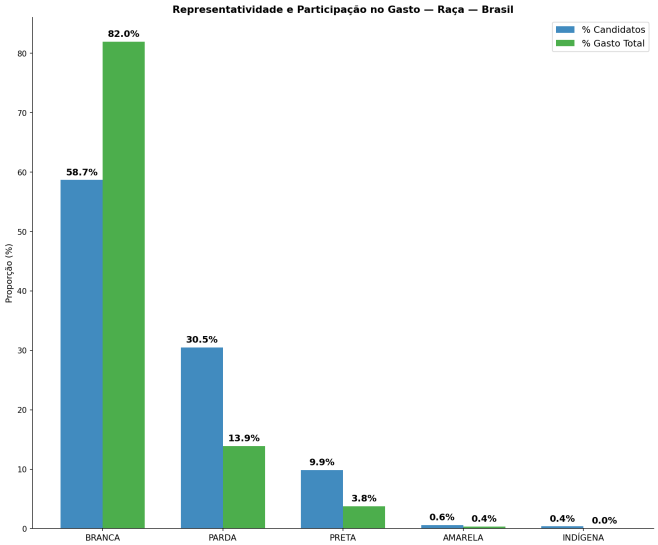

(c) Representatividade e gasto por raça.

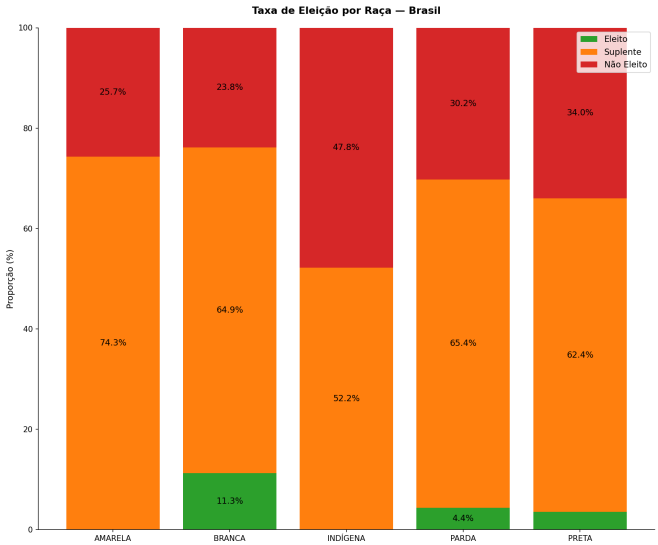

(d) Taxa de eleição por raça.

Figura 13: Desigualdades de financiamento e de resultado eleitoral no agregado nacional. Os gráficos mostram que grupos com menor acesso relativo a recursos também tendem a apresentar menor presença entre os eleitos.

V. Conclusão

Este artigo apresentou uma análise estatística descritiva do dataset D2 de eleições brasileiras de 2014, cobrindo integralmente os requisitos do briefing da disciplina e incorporando análises extras do notebook original.

Os resultados mostram que tanto gasto quanto votos possuem distribuições fortemente assimétricas à direita, o que torna a mediana uma medida muito mais representativa do candidato típico do que a média. A relação entre gasto e votos foi positiva no agregado nacional e em todos os estados analisados, com intensidades distintas: moderada em mercados eleitorais mais heterogêneos como o RJ, moderada a forte em GO, e forte no AM.

As análises complementares revelaram ainda duas dimensões substantivas do processo eleitoral de 2014. A primeira é a importância de estruturas intermediárias de campanha, como comitês partidários e fornecedores gráficos, na circulação dos recursos. A segunda é a persistência de desigualdades no acesso ao financiamento: homens e candidatos brancos concentram parcela dos recursos superior ao seu peso nas candidaturas, enquanto mulheres, pardos, pretos e indígenas aparecem subfinanciados.

Em síntese, o dataset confirma que recursos financeiros estão associados ao desempenho eleitoral, mas também sugere que o acesso desigual a esses recursos pode funcionar como barreira estrutural à competição política de grupos sub-

representados.