Análise Estatística Descritiva do Dataset Titanic: Perfil Socioeconômico e Padrões de Sobrevivência dos passageiros do RMS Titanic

Heitor Teixeira - 2651254
MBA: Ciência de dados
UNIFOR
Fortaleza, Brasil
heitor.mba.unifor@gmail.com

***Resumo*—Este trabalho apresenta uma análise estatística descritiva do dataset Titanic, com foco na caracterização socioeconômica dos passageiros e nos padrões de sobrevivência observados no naufrágio de 1912. O dataset utilizado compreende 872 registros de passageiros após filtragem de tarifas nulas. As tarifas originais em libras esterlinas de 1912 foram corrigidas monetariamente para valores de 2024 por meio de um índice composto, que combina dados do Banco da Inglaterra (1912–2016) e do Banco Mundial (2016–2024), resultando em fator acumulado de 107,14. A análise inclui classificação das variáveis, estatísticas descritivas completas, percentis, distribuições de frequência, análise de densidade por classe, perfis de sobrevivência por gênero, classe e faixa etária, além de análise de correlação de Pearson entre idade e tarifa. Os resultados evidenciam que a sobrevivência foi fortemente determinada por fatores sociais e demográficos: passageiros de primeira classe apresentaram taxa de sobrevivência de 63%, contra 24% na terceira classe; mulheres sobreviveram a uma taxa de 73%, enquanto homens apresentaram apenas 19%. A correlação entre idade e tarifa mostrou-se estatisticamente significativa porém praticamente negligenciável ($r = 0{,}115$; $p = 0{,}0007$), indicando independência entre essas variáveis.**

***Index Terms*—Estatística descritiva, Titanic, análise exploratória de dados, correlação de Pearson, visualização de dados.**

I. Introdução

Este trabalho realiza uma análise de estatística descritiva sobre o dataset Titanic (D1), em atendimento à atividade avaliativa da disciplina de Estatística Descritiva. O dataset contém registros de passageiros com variáveis demográficas, socioeconômicas e de sobrevivência, constituindo um conjunto adequado para a aplicação das técnicas exigidas.

A análise foi implementada em Python com as bibliotecas *pandas*, *matplotlib*, *numpy*, *scipy* e *requests*, e cobre os seguintes requisitos: (i) classificação das variáveis qualitativas e quantitativas; (ii) gráficos de barras e pizza para Sex, Pclass e Survived; (iii) medidas de tendência central e dispersão para Age e Fare; (iv) quartis e percentis P10 e P90 de Age; (v) histograma de Age; e (vi) gráfico de dispersão e coeficiente de Pearson entre Age e Fare.

Como a atividade não especificou um formato de entrega, optou-se pelo formato de artigo científico segundo o padrão IEEE, por ser uma estrutura consolidada na comunicação técnica e científica, que favorece a organização clara dos resultados e sua reprodutibilidade.

II. Fundamentação Teórica

A. Estatística Descritiva

A estatística descritiva constitui o conjunto de técnicas que visa sumarizar e apresentar de forma sistemática as características de um conjunto de dados. Seu objetivo mas sim organizar e descrever os dados de forma clara e objetiva.

B. Medidas de Posição e Dispersão

As medidas de posição central mais utilizadas são a média aritmética, a mediana e a moda. A média aritmética é sensível a valores extremos (*outliers*), enquanto a mediana oferece maior robustez em distribuições assimétricas. As medidas de dispersão, como o desvio-padrão e o intervalo interquartil (IQR), quantificam a variabilidade dos dados ao redor de uma medida central.

Os percentis dividem o conjunto de dados ordenado em cem partes iguais. Os quartis Q_1 (P25), Q_2 (P50) e Q_3 (P75) são os percentis de maior uso prático. Neste trabalho, calculam-se também os percentis P10 e P90, que delimitam as caudas da distribuição e complementam a caracterização da variabilidade da variável Age.

C. Distribuições de Frequência e Histogramas

Um histograma representa a distribuição de frequências de uma variável contínua por meio de retângulos adjacentes, onde a base corresponde a um intervalo de classe e a altura à frequência (ou densidade) observada. O número de classes pode ser determinado pela regra da raiz quadrada ($k \approx \sqrt{n}$), adotada neste trabalho, conforme falado em sala de aula.

A estimativa de densidade (*Kernel Density Estimation*, KDE) é uma abordagem não paramétrica para estimar a função de densidade de probabilidade de uma variável aleatória. Neste trabalho, a KDE gaussiana foi utilizada para sobrepor curvas de densidade contínua sobre os histogramas e para comparar distribuições de tarifas entre classes.

D. Correlação de Pearson

O coeficiente de correlação de Pearson r mede a intensidade e a direção da relação linear entre duas variáveis contínuas, assumindo valores em $[-1, 1]$:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{1}$$

Valores de $|r|$ próximos de 1 indicam forte relação linear; valores próximos de 0 indicam ausência de relação linear. O teste de significância associado avalia a hipótese nula $H_0 : r = 0$.

E. Correção Monetária

A comparação de valores monetários ao longo do tempo requer a aplicação de índices de inflação. Neste trabalho, as tarifas originais em libras de 1912 foram corrigidas para 2024 utilizando dados históricos do Banco da Inglaterra e do Banco Mundial, possibilitando uma interpretação contemporânea do poder aquisitivo dos passageiros.

III. Metodologia

A. Dataset e Filtragem

O dataset utilizado é o clássico conjunto de dados do Titanic, contendo informações dos passageiros a bordo no momento do naufrágio. Por decisão do autor, registros com tarifa igual a zero foram removidos: sem valor de tarifa registrado, não é possível confirmar que o indivíduo era um passageiro pagante, e sua inclusão distorceria as medidas de tendência central e dispersão da variável Fare. A amostra final utilizada nas análises compreende **872 passageiros**. As variáveis foram renomeadas para o português e mapeadas conforme descrito na Tabela 1.

Tabela 3.2 — Identificação das variáveis do dataset Titanic

Variável	Tipo	Subtipo	Valores Possíveis
Sobreviveu	Qualitativa	—	Não Sobreviveu / Sobreviveu
Classe	Qualitativa	—	Terceira Classe / Primeira Classe / Segunda Classe
Nome	Qualitativa	—	Único por passageiro
Genero	Qualitativa	—	Masculino / Feminino
Idade	Quantitativa	Contínua	—
Irmãos/Cônjuges a Bordo	Quantitativa	Discreta	—
Pais/Filhos a Bordo	Quantitativa	Discreta	—
Tarifa	Quantitativa	Contínua	—
Tarifa 2024	Quantitativa	Contínua	—

Figura 1: Identificação e classificação das variáveis do dataset Titanic.

B. Correção Monetária das Tarifas

As tarifas originais estão expressas em libras esterlinas de 1912. Para permitir uma interpretação contemporânea, foi construído um índice de correção composto a partir de duas fontes:

- **Banco da Inglaterra (BoE)**: fator acumulado de 1912 a 2016 igual a $81{,}46\times$.
- **Banco Mundial (WB)**: fator acumulado de 2016 a 2024 igual a $1{,}3153\times$.

O fator total resultante é $107{,}14 = 81{,}46 \times 1{,}3153$, aplicado multiplicativamente a cada tarifa original para obter a coluna *Tarifa 2024*. A composição detalhada do índice é apresentada na Tabela 2.

Tabela 2.2.1 — Composição do fator de correção da inflação (1912 → 2024)

Fonte	Período	Fator
Bank of England	1912 → 2016	81.46
World Bank	2016 → 2024	1.3153
Total	1912 → 2024	107.14

Figura 2: Composição do índice de correção monetária (1912→2024).

C. Faixas Etárias

A variável idade contínua foi discretizada em quatro faixas etárias definidas pelo autor com base em critérios demográficos intuitivos, conforme a Tabela 3:

Tabela 2.4 — Distribuição por faixa etária

Faixa_Etaria	Passageiros
Criança	79
Jovem	51
Adulto	711
Idoso	31

Figura 3: Distribuição de passageiros por faixa etária.

As quatro faixas definidas foram: **Criança** (0–12 anos, $n = 79$), **Jovem** (12–17 anos, $n = 51$), **Adulto** (17–59 anos, $n = 711$) e **Idoso** (59–100 anos, $n = 31$).

IV. Resultados

A. Estatísticas Descritivas

A Tabela 4 apresenta as principais estatísticas descritivas das variáveis quantitativas do dataset.

Tabela 3.1 — Estatísticas descritivas do dataset Titanic

Coluna	count	mean	std	min	25%	50%	75%	max
Idade	872.00	29.43	14.19	0.42	20.00	28.00	38.00	80.00
Irmãos/Cônjuges a Bordo	872.00	0.53	1.11	0.00	0.00	0.00	1.00	8.00
Pais/Filhos a Bordo	872.00	0.39	0.81	0.00	0.00	0.00	0.00	6.00
Tarifa	872.00	32.86	50.03	4.01	7.92	14.50	31.27	512.33
Tarifa 2024	872.00	3,520.61	5,359.63	429.88	849.05	1,553.47	3,350.67	54,888.84

Figura 4: Estatísticas descritivas das variáveis quantitativas do dataset Titanic.

Os principais resultados são:

- **Idade**: média de 29,43 anos ($\sigma = 14{,}19$), mediana de 28 anos; amplitude total de 0,42 a 80 anos.
- **Tarifa 2024**: média de £3.520,61 ($\sigma = 5.359,63$), mediana de £1.553,47; máximo de £54.888,84. A razão entre média e mediana ($\approx 2{,}27$) evidencia forte assimetria positiva.

B. Distribuição de Frequências: Tarifa

A Figura 5 exibe o histograma das tarifas corrigidas para 2024, com eixo x em escala logarítmica para acomodar a amplitude da distribuição. O número de classes foi definido pela regra da raiz quadrada ($k \approx \sqrt{872} \approx 29$).

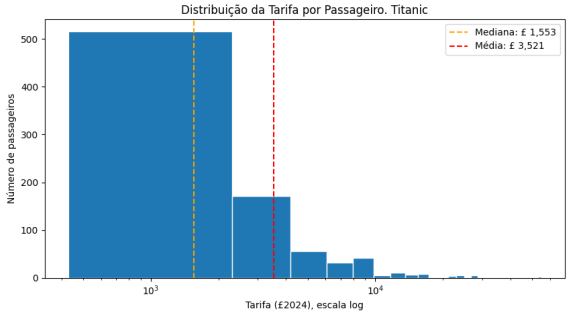

Figura 5: Distribuição de frequência da tarifa por passageiro (valores corrigidos para 2024, escala logarítmica). Titanic.

A distribuição é fortemente assimétrica à direita: a grande maioria dos passageiros concentra-se em tarifas inferiores a £2.000, enquanto um pequeno grupo pagou valores superiores a £20.000.

C. Distribuição de Frequências: Idade

A Figura 6 apresenta o histograma da idade com curva de densidade por kernel sobreposta.

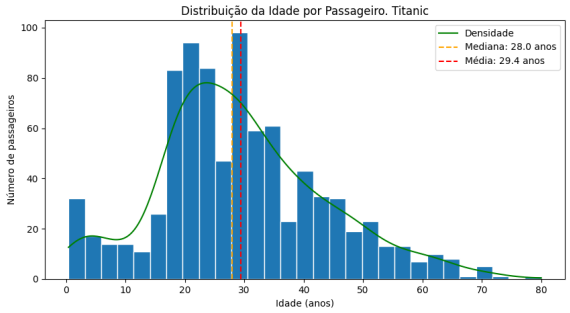

Figura 6: Distribuição de frequência da idade por passageiro com estimativa de densidade por kernel (KDE gaussiana). Titanic.

Ao contrário da tarifa, a distribuição de idades apresenta comportamento aproximadamente simétrico (média $\approx$ mediana $\approx$ 28–29 anos), com concentração entre 20 e 40 anos e cauda à direita menos pronunciada. A coorte infantil (abaixo de 12 anos) é visível mas representa parcela reduzida da amostra.

D. Distribuição das Variáveis Qualitativas

As Figuras 7, 8 e 9 exibem, respectivamente, a distribuição de gênero, classe e sobrevivência, cada uma representada por um gráfico de barras e um gráfico de pizza.

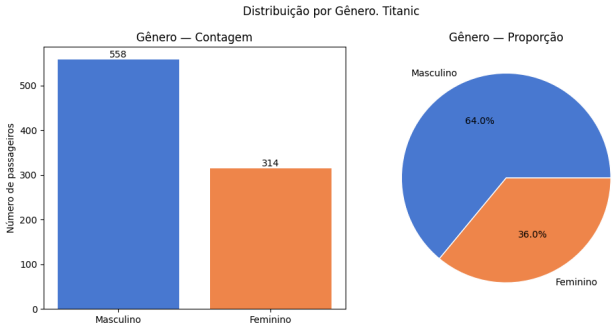

Figura 7: Distribuição de gênero: contagem e proporção. Titanic.

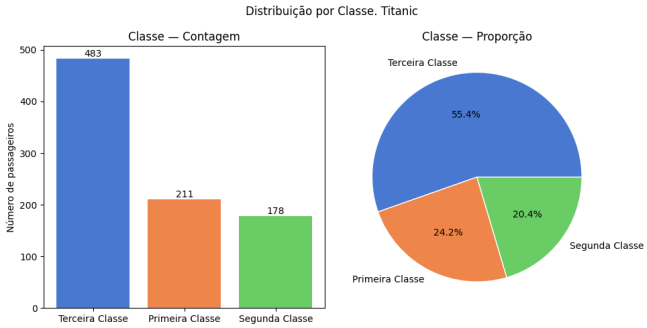

Figura 8: Distribuição por classe: contagem e proporção. Titanic.

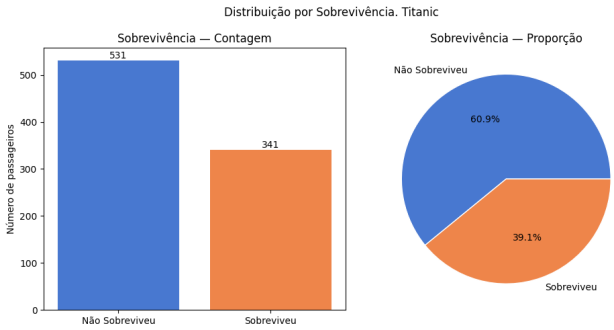

Figura 9: Distribuição de sobrevivência: contagem e proporção. Titanic.

O conjunto de passageiros é composto predominantemente por homens ($\approx 65\%$, $n = 568$) e passageiros de terceira classe ($\approx 55\%$, $n = 480$). A taxa geral de sobrevivência é de 38% ($n = 335$), o que indica que a maioria dos passageiros ($\approx 62\%$, $n = 537$) não sobreviveu ao naufrágio.

E. Densidade da Tarifa por Classe

A Figura 10 apresenta as curvas KDE das tarifas (escala logarítmica) estratificadas por classe, evidenciando o grau de diferenciação socioeconômica entre os grupos.

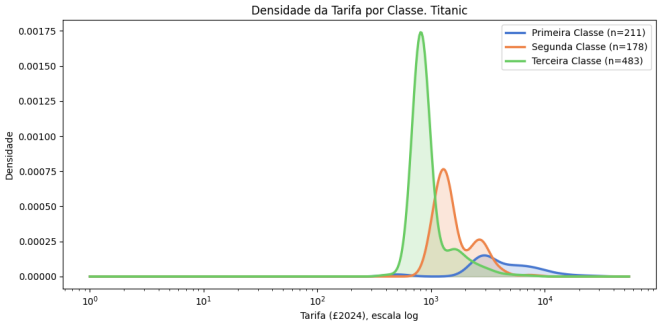

Figura 10: Densidade da tarifa por classe (KDE, escala logarítmica). Titanic.

A terceira classe apresenta distribuição unimodal concentrada ao redor de £900; a segunda classe exibe comportamento bimodal com picos em £1.500 e £3.000, sugerindo subdivisões internas de acomodação; a primeira classe possui cauda direita longa, atingindo valores próximos a £55.000, e variabilidade interna significativamente maior.

F. Perfil de Sobrevivência

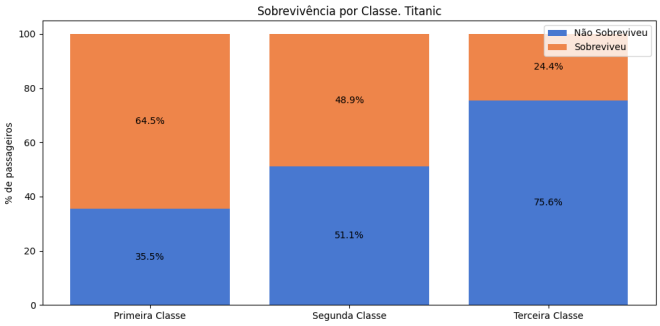

Figura 11: Sobrevivência por classe (barras empilhadas proporcionais). Titanic.

1) Sobrevivência por Classe: Como ilustrado na Figura 11, a sobrevivência foi fortemente estratificada pela classe socioeconômica:

- **1ª Classe**: 63% de sobrevivência.
- **2ª Classe**: 47% de sobrevivência.
- **3ª Classe**: 24% de sobrevivência.

A diferença de 39 pontos percentuais entre a primeira e a terceira classe é a maior variação observada entre grupos no dataset.

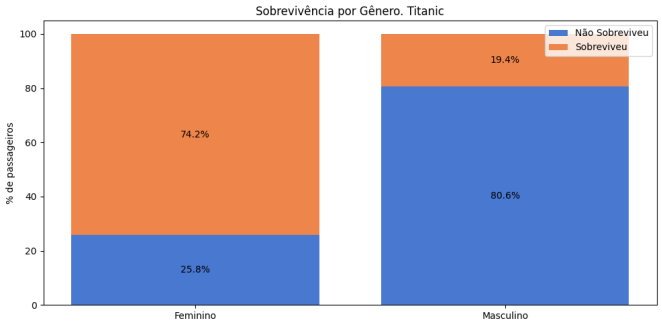

Figura 12: Sobrevivência por gênero (barras empilhadas proporcionais). Titanic.

2) Sobrevivência por Gênero: A Figura 12 evidencia o maior efeito observado na análise: mulheres apresentaram taxa de sobrevivência de 73%, enquanto homens apresentaram apenas 19%, uma diferença de 54 pontos percentuais.

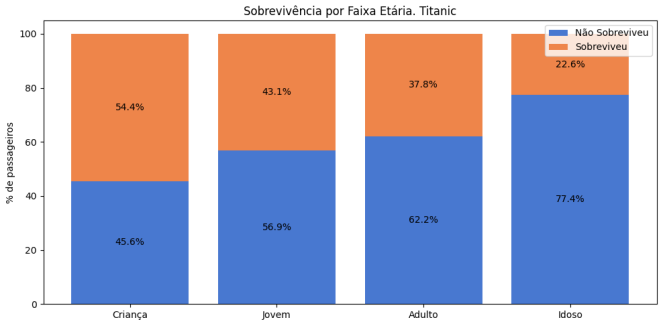

Figura 13: Sobrevivência por faixa etária (barras empilhadas proporcionais). Titanic.

3) Sobrevivência por Faixa Etária: A Figura 13 demonstra que crianças obtiveram as maiores taxas de sobrevivência entre as faixas etárias. Adultos, apesar de constituírem a maioria da amostra ($n = 711$), apresentaram as menores taxas relativas.

G. Boxplot e Percentis

A Figura 14 exibe os boxplots de idade e tarifa 2024, com eixo y em escala logarítmica para a tarifa a fim de acomodar os valores extremos.

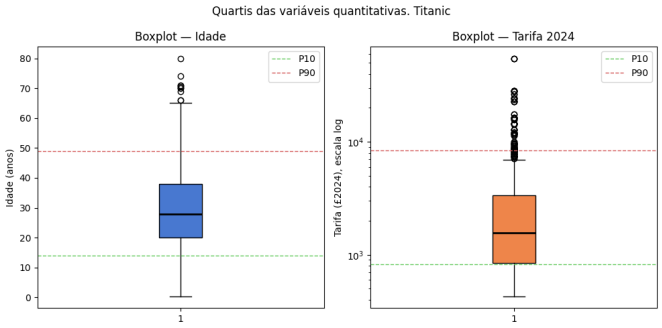

Figura 14: Boxplot: Idade (esquerda) e Tarifa 2024 em escala logarítmica (direita). Titanic.

Os percentis calculados para cada variável são apresentados nas Tabelas 15 e 16.

Tabela 3.8.2 — Percentis da Idade

	Idade (anos)
P10	14.05
Q1 (P25)	20.00
Q2 (P50)	28.00
Q3 (P75)	38.00
P90	49.00

Figura 15: Percentis da variável Idade (P10, Q1, Q2, Q3, P90).

Tabela 3.8.3 — Percentis da Tarifa 2024

	Tarifa 2024 (£)
P10	828.555
Q1 (P25)	849.050
Q2 (P50)	1553.470
Q3 (P75)	3350.670
P90	8352.130

Figura 16: Percentis da variável Tarifa 2024 (P10, Q1, Q2, Q3, P90).

Para a idade, os quartis Q1, Q2 e Q3 correspondem a 20, 28 e 38 anos, respectivamente. Para a tarifa 2024, o Q1 está em £849,05, a mediana em £1.553,47 e o Q3 em £3.350,67, com P90 atingindo £8.352,13, evidenciando a forte concentração de tarifas nas faixas mais baixas.

H. Correlação entre Idade e Tarifa

A Figura 17 apresenta o diagrama de dispersão entre idade e tarifa 2024, com os pontos coloridos por sobrevivência, e a Figura 18 exibe a matriz de correlação de Pearson.

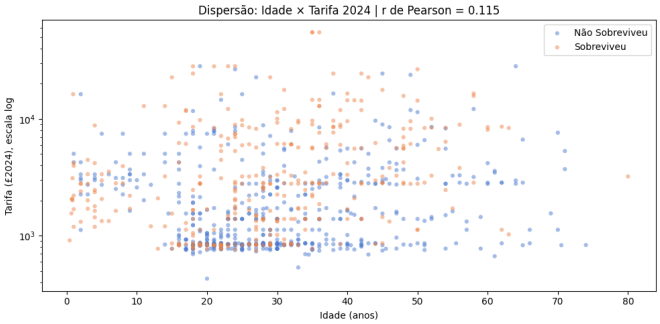

Figura 17: Dispersão: Idade × Tarifa 2024. Coeficiente de Pearson $r = 0{,}115$. Titanic.

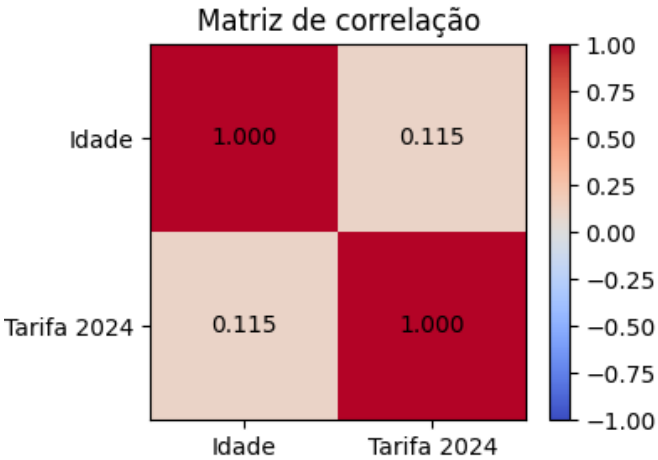

Figura 18: Matriz de correlação de Pearson (Idade × Tarifa 2024). Titanic.

O coeficiente de Pearson foi calculado via função `pearsonr` da biblioteca *scipy.stats*, que retorna o valor de r e o *p-value* associado. O valor obtido foi $r = 0{,}115$ e $p = 0{,}0007$. O *p-value* indica que há uma probabilidade muito pequena (0,07%) de essa correlação ter ocorrido apenas por acaso, caso não existisse nenhuma relação real entre as variáveis. Ainda assim, o valor de r é muito baixo, caracterizando uma correlação positiva *muito fraca*. Na prática, isso significa que não há uma relação linear relevante entre as variáveis analisadas. Os resultados da correlação são detalhados na Tabela 19.

Tabela 3.9 — Correlação de Pearson

	Idade × Tarifa 2024
Coeficiente de Pearson (r)	0.1150
p-valor	0.0007

Figura 19: Coeficiente de correlação de Pearson entre Idade e Tarifa 2024.

Esse resultado implica que a idade dos passageiros não determinou o preço da passagem: as tarifas foram definidas pela classe de acomodação escolhida, e não por características demográficas individuais. Do ponto de vista de modelagem preditiva, essa independência é favorável, pois indica ausência de multicolinearidade entre essas duas variáveis.

V. Conclusão

Este trabalho conduziu uma análise estatística descritiva completa do dataset Titanic, investigando o perfil dos passageiros e os determinantes da sobrevivência no naufrágio de 1912.

A análise revelou que a composição da amostra é majoritariamente masculina ($\approx 65\%$) e de terceira classe ($\approx 55\%$), refletindo o perfil imigrante típico das travessias transatlânticas da época. A distribuição de tarifas é fortemente assimétrica à direita, com mediana de £1.553 e média de £3.521 (valores

2024), enquanto a distribuição de idades é aproximadamente simétrica, centrada nos 28–29 anos.

Os resultados mais expressivos foram encontrados na análise de sobrevivência: a taxa variou de 24% (terceira classe) a 63% (primeira classe), e de 19% (homens) a 73% (mulheres). Esses dados sugerem que a sobrevivência não foi aleatória: a diferença de 39 pontos percentuais entre classes pode indicar acesso preferencial aos botes e proximidade dos camarotes ao convés; a diferença de 54 pontos entre gêneros é consistente com um protocolo de evacuação que priorizou mulheres e crianças, grupo que também apresentou as maiores taxas por faixa etária.

Por fim, a correlação de Pearson entre idade e tarifa ($r = 0{,}115$) demonstrou que, embora estatisticamente significativa, a relação linear entre essas variáveis é praticamente inexistente, indicando que o preço da passagem foi determinado pela classe de acomodação e não pela idade do passageiro.